Machine Learning Lab 4

Альромхин Джорж, гр.858301


```
In [1]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import scipy.optimize as opt
import scipy.io
import matplotlib.image as mpimg
```

load Data.

```
In [2]: data = scipy.io.loadmat('../Data/lab4/ex4data1.mat')
    x = np.array(data['X'])
    y = np.squeeze(data['y'])
    np.place(y, y == 10, 0)
    n = x.shape[1]
    m = x.shape[0]
    num_labels = 10
    input_layer_size = 400  # 20x20 Input Images of Digits
    hidden_layer_size = 25  # 25 hidden units
```

```
In [3]: subplots = 64
    draw_seed = np.random.randint(low=0, high=x.shape[0], size=subplots)
    draw_rows = x[draw_seed]
    fig, ax = plt.subplots(8, 8, figsize=(8, 8))
    for i, axi in enumerate(ax.flat):
        data = np.reshape(draw_rows[i], (20, 20), order='F')
        axi.imshow(data, cmap='binary')
        axi.set(xticks=[], yticks=[])

plt.show()
```



Загрузите веса нейронной сети из файла ex4weights.mat, который содержит две матрицы $\Theta(1)$ (25, 401) и $\Theta(2)$ (10, 26). Какова структура полученной нейронной сети?

```
In [16]: weights = scipy.io.loadmat('ex4weights.mat')
# Theta1 has size 25 x 401
# Theta2 has size 10 x 26
theta1, theta2 = weights['Theta1'], weights['Theta2']
# swap first and last columns of Theta2, due to legacy from MATLAB index
# since the weight file ex3weights.mat was saved based on MATLAB indexiintheta2 = np.roll(theta2, 1, axis=0)
```

Данная нейроная сеть содержит 3 слоя: входной слой из 400 узлов, сткрытый слой из 25 узлов и выходной слой на 10 узлов.

Реализуйте функцию прямого распространения с сигмоидом в качестве функции активации.

```
In [5]: def sigmoid(X):
    return 1 / (1 + np.exp(-X))

def predict(X, theta1, theta2):
    m = X.shape[0]
    X = np.hstack((np.ones((m, 1)), X))
    a1 = sigmoid(X.dot(theta1.T))
    a1 = np.hstack((np.ones((m, 1)), a1)) # hidden layer
    a2 = sigmoid(a1.dot(theta2.T)) # output layer
    return np.argmax(a2, axis=1)
```

Вычислите процент правильных классификаций на обучающей выборке. Сравните полученный результат с логистической регрессией.

```
In [8]: p = predict(x, theta1, theta2)
print(f'Prediction on training set: {np.mean(p == y) * 100}%')

Prediction on training set: 97.52%
```

Использую логистическую регрессию в лабораторной 2 была полученна точность 94.74%. Точность предсказаний данной нейронной сети на 2.8% лучше.

Перекодируйте исходные метки классов по схеме one-hot.

```
In [26]: y_matrix = np.eye(num_labels)[y]
```

Реализуйте функцию стоимости для данной нейронной сети.

Добавьте L2-регуляризацию в функцию стоимости.

```
In [29]: # Add regularization term
lambda_ = 1
reg_term = (lambda_ / (2 * m)) * (np.sum(np.square(thetal[:, 1:])) + np.
cost_reg = cost + reg_term
print(f'Cost(regularized): {cost_reg}')
```

Cost(regularized): 0.38376985909092365

Реализуйте функцию вычисления производной для функции активации.

```
In [34]: print(f'For large values gradient should be close to zero, sigmoidGradie
    For large values gradient should be close to zero, sigmoidGradient(100
    0) = 0.0
```

```
In [38]: print(f'Gradient should be exacly 0.25 for 0, sigmiodGradient(0) = {sign
Gradient should be exacly 0.25 for 0, sigmiodGradient(0) = 0.25
```

Инициализируйте веса небольшими случайными числами.

```
In [40]: def rand_init_weights(l_in, l_out, epsilon=0.12):
    return np.random.rand(l_out, 1 + l_in) * 2 * epsilon - epsilon

In [43]: initial_theta1 = rand_init_weights(input_layer_size, hidden_layer_size)
    initial_theta2 = rand_init_weights(hidden_layer_size, num_labels)
```

Реализуйте алгоритм обратного распространения ошибки для данной конфигурации сети.

```
In [50]: def nn cost function(nn params, input layer size, hidden layer size, nur
                                      thetal = np.reshape(nn params[:hidden layer size * (input layer size
                                                                                          (hidden layer size, (input layer size + 1)))
                                   theta2 = np.reshape(nn params[(hidden layer size * (input layer size
                                                                                          (num labels, (hidden layer size + 1)))
                                   m = y.size
                                    # Feedforward propagation
                                   a1 = np.hstack([np.ones((m, 1)), X])
                                   a2 = sigmoid(a1.dot(theta1.T))
                                   a2 = np.hstack([np.ones((a2.shape[0], 1)), a2])
                                   a3 = sigmoid(a2.dot(theta2.T))
                                    # Cost calc
                                   y = y.reshape(-1)
                                   y matrix = np.eye(num labels)[y matrix]
                                    reg\_term = (lambda\_ / (2 * m)) * (np.sum(np.square(thetal[:, 1:])) + (p.sum(np.square(thetal[:, 1:])) + (p.sum(np.squar
                                    J = (-1 / m) * np.sum((np.log(a3) * y_matrix) + np.log(1 - a3) * (1)
                                    # Backpropogation
                                   delta_3 = a3 - y_matrix
                                    delta 2 = delta 3.dot(theta2)[:, 1:] * sigmoidGradient(a1.dot(theta1
                                   delta1 = delta 2.T.dot(a1)
                                   delta2 = delta_3.T.dot(a2)
                                    # Add regularization to gradient
                                   theta1_grad = (1 / m) * delta1
                                    thetal grad[:, 1:] = thetal_grad[:, 1:] + (lambda_ / m) * thetal[:,
                                    theta2 grad = (1 / m) * delta2
                                    theta2 grad[:, 1:] = theta2 grad[:, 1:] + (lambda / m) * theta2[:,
                                   grad = np.concatenate([theta1 grad.ravel(), theta2 grad.ravel()])
                                    return J, grad
```

Для того, чтобы удостоверится в правильности вычисленных значений градиентов используйте метод проверки градиента с параметром $\epsilon = 10$ -4.

```
In [72]: def compute_numerical_gradient(J, theta, e=1e-4):
    numgrad = np.zeros(theta.shape)
    perturb = np.diag(e * np.ones(theta.shape))
    for i in range(theta.size):
        cost1, _ = J(theta - perturb[:, i])
        cost2, _ = J(theta + perturb[:, i])
        numgrad[i] = (cost2 - cost1) / (2 * e)
    return numgrad
```

```
In [82]: def check_nn_gradients(nn_cost_function, lambda_=0.0):
             input layer size = 3
             hidden layer size = 5
             num\ labels = 3
             m = 5
             # We generate some 'random' test data
             theta1 = rand_init_weights(hidden_layer_size-1, input_layer_size+1)
             theta2 = rand init weights(num labels-1, hidden_layer_size+1)
             X = rand init weights(m-1, input layer size)
             X = X.reshape(m, num_labels)
             y = np.arange(1, 1+m) % num labels
             # Unroll parameters
             nn params = np.concatenate([theta1.ravel(), theta2.ravel()])
             # short hand for cost function
             cost func = lambda p: nn cost function(p, input layer size, hidden l
                                                 num_labels, X, y, lambda_)
             cost, grad = cost_func(nn params)
             numgrad = compute numerical gradient(cost func, nn params)
             # Visually examine the two gradient computations.The two columns you
             print('The two columns you get should be very similar.')
             print('(Left-Your Numerical Gradient, Right-Analytical Gradient)')
             print(np.stack([numgrad[:5], grad[:5]], axis=1))
             # Evaluate the norm of the difference between two the solutions. If
             # implementation, and assuming you used e = 0.0001, then diff
             # should be less than 1e-9.
             diff = np.linalg.norm(numgrad - grad)/np.linalg.norm(numgrad + grad)
             print('If backpropagation implementation is correct, then \n'
                   'the relative difference will be small (less than 1e-9). \n'
                   f'Relative Difference: {diff}')
In [83]: check nn gradients(nn cost function)
         The two columns you get should be very similar.
         (Left-Your Numerical Gradient, Right-Analytical Gradient)
         [-8.69657746e-05 -8.69657754e-05]
          [ 4.72294761e-04 4.72294764e-04]
          [ 1.21512829e-04 1.21512831e-04]
          [-6.56266561e-04 -6.56266565e-04]]
         If backpropagation implementation is correct, then
         the relative difference will be small (less than 1e-9).
         Relative Difference: 2.9930853667124326e-11
```

Добавьте L2-регуляризацию в процесс вычисления градиентов. Проверьте полученные значения градиента.

```
In [84]: check_nn_gradients(nn_cost_function, lambda_=1.0)

The two columns you get should be very similar.
  (Left-Your Numerical Gradient, Right-Analytical Gradient)
  [[-0.00015403 -0.00015403]
      [-0.00517767 -0.00517767]
      [-0.01576813 -0.01576813]
      [ 0.00205132   0.00205132]
      [-0.00560234 -0.00560234]]
      If backpropagation implementation is correct, then the relative difference will be small (less than 1e-9).
      Relative Difference: 1.8415564955692822e-11
```

Обучите нейронную сеть с использованием градиентного спуска или других более эффективных методов оптимизации.

```
In [57]: def nn_gradient_descent(nn_params, cost_func, alpha, num_iters):
    j_history = []
    for i in range(0, num_iters):
        cost, grad = cost_func(nn_params)
        nn_params -= alpha * grad
        j_history.append(cost)

    return nn_params, j_history
```

Cost on trained network using gradient descent: 0.5730019815532197

Вычислите процент правильных классификаций на обучающей выборке.


Prediction on training set using gradient descent: 93.38%

Визуализируйте скрытый слой обученной сети.

```
In [63]: def visualize_data(input, display_rows=5, display_cols=5, figsize=(10, 1)
    subplots = display_rows * display_cols
    fig, ax = plt.subplots(display_rows, display_cols, figsize=figsize)
    for i, axi in enumerate(ax.flat):
        data = np.reshape(input[i], (20, 20), order='F')
        axi.imshow(data, cmap='binary')
        axi.set(xticks=[], yticks=[])

plt.show()
```


In [64]: visualize_data(theta1[:, 1:])



Подберите параметр регуляризации. Как меняются изображения на скрытом слое в зависимости от данного параметра?

In [69]: test_lambda(0)


Cost on trained network with regularization lambda = 1: 0.1716186839513631



In [70]: | test_lambda(1)

Cost on trained network with regularization lambda = 1: 0.371903119043 98177


Prediction on training set wit regularization lambda = 1: 97.72%



In [71]: test_lambda(20)

Cost on trained network with regularization lambda = 1: 1.3447246106101214

Prediction on training set wit regularization lambda = 1: 92.06%



По изображениям заметно что чем большее параметр регаляризации, тем более размытой становиться картинка.